

Predicción del PROMEDIO_GLOBAL de Saber Pro mediante LightGBM y auditoría de fuga temporal: un estudio a nivel de programa académico en Colombia

Edwin Santiago Paz Bedoya
Nathalia Orozco Morales

UNIMINUTO Virtual – Bogotá, Colombia

edwin.paz@uniminuto.edu
nathalia.orozco@uniminuto.edu

Problema y objetivo de investigación

Objetivo

Estimar el PROMEDIO_GLOBAL de la siguiente aplicación a partir del historial público de cada programa


Unidad de análisis

Institución · programa · prueba · año

Alcance: predicción agregada y apoyo a revisión académica

Datos ICFES y construcción del panel

127.716 filas procesadas



Reportes ICFES 2020–2024

Datos agregados

Estadísticas reorganizadas
en columnas

Historial por entidad

Fuga de información y separación temporal

Entrenamiento 2020–2023
98.954 filas

Prueba 2024
28.762 filas

Excluir puntajes y medidas del mismo ciclo

Construir rezagos con observaciones anteriores

Calcular tendencias sin incluir el resultado actual

Pendiente de revisión: las divisiones internas mezclan años

Modelos evaluados

Ridge y Lasso

Referencias lineales con regularización

LightGBM


50 ensayos Optuna · 188 árboles finales

Transformer encoder

2 capas · 4 cabezas · secuencias por entidad

Comparación limitada a las configuraciones e información disponibles

Resultado principal de LightGBM



RMSE 9,3293

MAE 6,2109

R² 0,7062

Evaluación externa en 2024
28.762 observaciones


Comparación en el conjunto de prueba 2024

Modelo	RMSE	MAE	R ²
Ridge	10,2294	7,2967	0,6467
Lasso	10,0722	7,0622	0,6575
LightGBM	9,3293	6,2109	0,7062
Transformer	16,8588	n/d	0,0405

LightGBM reduce 7,4 % el RMSE frente a Lasso

Resultados aceptados. Un año de prueba; sin intervalos formales.

Interpretabilidad mediante SHAP




Mayor influencia del historial

1. Rezago global más reciente
2. Segundo rezago global
3. Rezago de la prueba

Asociación predictiva
sin interpretación causal

Errores y límites de generalización



RMSE por departamento

Sucre 13,29 (n = 366)

Chocó 12,03 (n = 243)

Putumayo 11,18 (n = 54)

Cinco años de datos

Un único año de prueba

Sin covariables socioeconómicas

Conclusiones y trabajo futuro

Resultado

LightGBM: RMSE 9,33 y R^2 0,706 en 2024

Alcance

Historial útil, datos agregados y evidencia de un solo corte

Trabajo futuro

Varios cortes temporales, revisión de variables y validación institucional