

Predicción del PROMEDIO_GLOBAL de Saber Pro mediante LightGBM y auditoría de fuga temporal: un estudio a nivel de programa académico en Colombia

Edwin Santiago Paz Bedoya
Nathalia Orozco Morales

UNIMINUTO Virtual – Bogotá, Colombia

Problema y objetivo

Problema


Los resultados de Saber Pro se publican meses después de la aplicación del examen.

Objetivo

Estimar el PROMEDIO_GLOBAL a nivel de programa con información histórica pública del ICFES.

Datos y construcción del panel

127.716 observaciones procesadas



Reportes ICFES 2020–2024

Unidad de análisis
Institución, programa,
prueba y año

Historial por entidad

Control de fuga y esquema de evaluación

Entrenamiento 2020–2023
98.954 filas

Test externo 2024
28.762 filas

Exclusión de puntajes y niveles de desempeño del mismo ciclo

Rezagos contruidos con las observaciones anteriores disponibles

Modelos evaluados

Ridge y Lasso

Regresión lineal con penalización L2 (Ridge) y L1 (Lasso)

LightGBM


Boosting de árboles. Búsqueda con 50 trials de Optuna

Transformer encoder

Atención sobre secuencias históricas por entidad

Comparación de las configuraciones evaluadas, con diferencias en sus entradas

Desempeño global de LightGBM



RMSE 9,33

MAE 6,21

R^2 0,706


Test externo 2024
 $n = 28.762$

Comparación de modelos

Modelo	RMSE	MAE	R ²
Ridge	10,2294	7,2967	0,6467
Lasso	10,0722	7,0622	0,6575
LightGBM	9,3293	6,2109	0,7062
Transformer	16,8588	n/d	0,0405

LightGBM obtuvo el menor RMSE y el mayor R² en el conjunto de prueba 2024.

Interpretabilidad mediante SHAP




Principales contribuciones predictivas observadas

1. Rezago reciente del PROMEDIO_GLOBAL
2. Segundo rezago global
3. Rezago de la prueba

SHAP describe contribuciones a la predicción, sin causalidad.

Análisis de error y limitaciones



RMSE por departamento

Sucre ≈ 13 puntos

Chocó ≈ 12 puntos

Putumayo ≈ 11 puntos

Un único año de prueba
Datos agregados, sin covariables
socioeconómicas
Heterogeneidad del error
entre grupos

Conclusiones

1. LightGBM alcanzó RMSE 9,33 y R^2 0,706 en el test 2024.
2. Los rezagos históricos contienen la mayor señal predictiva observada.
3. Se requiere ampliar la validación temporal y revisar la heterogeneidad entre grupos antes de un uso institucional.

Trabajo futuro: validación walk-forward, revisión de variables y evaluación institucional.